

基于可解释深度学习与 DNA 大模型的 拟南芥顺式调控代码解码及调控变异效应预测 ——研究方案设计报告

姓名：_____ 学号：_____

专业：_____ 指导教师：_____

2026 年 8 月 5 日

摘要

植物基因组中非编码区承载着决定基因“何时、何地、以何种水平表达”的顺式调控信息，而“序列—调控”的映射规律至今仍未完全解码。本课题以模式植物拟南芥 (*Arabidopsis thaliana*) 为研究对象，从基因侧翼序列（启动子、5' UTR、3' UTR、终止子）出发，构建“序列 → 表达水平”的端到端深度学习预测模型，系统解码决定表达高低的顺式调控代码，并进一步预测调控变异（SNP/InDel）对表达的影响。课题包含四大研究内容：(i) 自建拟南芥侧翼序列—表达数据集与官方 PGB 标准基准的双轨数据体系（染色体级防泄漏划分）；(ii) 统一基准下 1D-CNN 基线（DeepSEA/Basenji 风格）与农业 DNA 大模型 AgroNT（LoRA 微调）的系统对比，覆盖分类/回归双任务与性能—成本权衡；(iii) DeepLIFT 归因 → 区域重要性量化 → TF-MoDISco 模体发现 → DAP-seq/JASPAR 比对的可解释性链路；(iv) 以 1001 Genomes 自然变异与公开 eQTL 数据验证 in silico 变异效应打分的纯干实验闭环，并考察跨物种泛化。课题全程为纯干实验、机器学习主体，单张 24GB 消费级 GPU 可行，总工作量约 20 周，面向中科院三区期刊（首选 Genes, MDPI）发表。

关键词：拟南芥；顺式调控代码；基因表达预测；DNA 大模型；可解释性；调控变异效应；纯干实验

目录

0. 一页总结	3
1 选题背景与研究意义	3
1.1 研究背景	3
1.2 研究意义	4
2 国内外研究现状与本课题差异化	4
2.1 研究现状	4
2.2 2025 年同类工作与本课题对比	4
2.3 现有工作的不足与本课题切入点	4

目录	2
3 研究目标与研究内容	4
3.1 总体目标	4
3.2 研究内容一：数据与基准构建	6
3.3 研究内容二：统一基准模型对比	6
3.4 研究内容三：可解释性与调控代码解码	6
3.5 研究内容四：调控变异效应预测与自然变异验证（差异化亮点）	6
4 技术路线	7
5 数据来源与方法详述	7
5.1 数据资源汇总	7
5.2 特征与标签	7
5.3 模型架构	7
5.4 训练与优化	9
5.5 评估指标	9
5.6 可解释性方法	9
5.7 变异效应预测方法	10
6 预期成果与图件规划	10
6.1 预期成果	10
6.2 图件规划（4-5 主图 + 2-3 附图）	10
7 工作量拆解与进度安排	11
8 可行性分析	11
9 风险与对策	13
10 三区期刊定位与选刊建议	13
11 前期基础与实现保障	13
12 总结	13

0. 一页总结

以模式植物拟南芥 (*Arabidopsis thaliana*) 为对象, 从基因侧翼序列 (启动子、5 UTR、3 UTR、终止子) 出发, 构建”序列 → 表达水平”的端到端深度学习预测模型, 系统解码决定表达高低的顺式调控代码, 并进一步预测调控变异 (SNP/InDel) 对表达的影响, 用 1001 Genomes 自然变异与公开 eQTL 数据进行纯干实验验证。

表 1 方案定位总览

维度	内容
研究对象	拟南芥 (<i>Arabidopsis thaliana</i>), TAIR10/Araport11 注释, 约 2.7 万个基因
研究范式	纯干实验, 机器学习主体, 无需湿实验, 单卡 GPU 可行
四大研究内容	数据与基准构建; 统一基准模型对比 (CNN vs AgroNT); 可解释性解码; 调控变异效应预测与验证 (差异化亮点)
目标期刊	首选 Genes (MDPI) (中科院 3 区, Takou 2025 同类型工作即发表于此); 备选 Frontiers in Genetics、BMC Genomics、Planta、Scientific Reports
工作量	约 20 周 (含投稿前准备), 核心 GPU 计算约 6-8 周
预期产出	可复现管线 + 训练模型 + 统一基准评估 + 模体清单/区域重要性 + 变异效应图谱 + 论文 1 篇 (4-5 主图 + 2-3 附图)

关键差异化 (相对 2025 年 DeepPlantCRE、nemo、GenoRetriever 等同类工作): 强调**统一基准下 CNN 与 DNA 大模型的系统对比**与**以自然变异/eQTL 数据做变异效应验证**, 而不仅是”预测 + 模体发现”。

1 选题背景与研究意义

1.1 研究背景

植物基因组中编码区占比小, 占主体的非编码区承载着决定基因”何时、何地、以何种水平表达”的顺式调控信息, 由**顺式调控元件** (cis-regulatory element, CRE) ——启动子、5 UTR、3 UTR、终止子等共同介导。解析 CRE 的序列编码规律, 是理解基因表达调控、解释自然变异如何影响表型的前提, 也是”从基因组到表型”预测的核心一环 [1]。

以卷积神经网络 (CNN) 为代表的深度学习方法已在哺乳动物基因组上证明: 仅凭 DNA 序列即可高精度预测转录因子结合、染色质状态与基因表达 [3, 4]。在植物中, Peleke 等 (2024) 证明从基因侧翼序列预测拟南芥、番茄、高粱、玉米的**基础表达水平** (高/低二分类) 准确率可达 80% 以上 (AUROC 0.92-0.94), 并通过 DeepLIFT 与 TF-MoDISco 识别出与已知转录因子结合位点一致的表达相关模体 [2]。

本课题在该范式之上, 向两个方向深化:

1. **方法纵深**: 在统一基准上系统对比 1D-CNN 与农业 DNA 大模型 (AgroNT[5]), 给出可复用的性能—成本参照;

2. **应用延伸**：将模型延伸为**调控变异效应预测**工具，用 1001 Genomes 自然变异与公开 eQTL 数据形成纯干实验验证闭环。

1.2 研究意义

1. **科学意义**：量化”哪些区域（启动子/UTR/终止子）、哪些模体、以何种组合决定表达水平”，推进植物顺式调控代码的解析，回答表达调控的序列编码这一基础问题。
2. **方法意义**：首次在统一植物基准（PGB[6]）上给出 1D-CNN 与 DNA 大模型（AgroNT）的性能—成本权衡，为植物基因组深度学习建模提供参照基准 [5]。
3. **应用价值**：模型可用于（i）新基因组中未注释基因的表达预判；（ii）**非编码变异的调控效应打分与优先排序**，为关联分析结果提供功能解释，服务分子设计育种。

2 国内外研究现状与本课题差异化

2.1 研究现状

1. **基础表达预测已可靠**：Peleke 2024 四物种 CNN 模型，以侧翼序列（启动子 1 kb + 5 UTR 0.5 kb + 3 UTR 0.5 kb + 终止子 1 kb）预测高/低表达，分类准确率 >80%，含跨物种迁移与基因型间表达预测；归因发现 UTR 是重要性最高的侧翼特征 [2]。
2. **条件性表达预测仍有挑战**：Takou 2025 从五个自然生态型的近端序列预测冷响应差异表达基因，测试集 prAUC 仅约 0.70；作者指出需整合染色质状态等额外信息，说明环境响应性表达预测难度显著高于基础表达预测 [7]。
3. **DNA 大模型兴起**：AgroNT（1B 参数 Transformer，48 物种预训练，6-mer token）在 PGB 的 8 类任务上达 SOTA，支持零样本变异效应评估 [5]；PGB 提供了标准化的植物基因组基准任务与官方划分 [6]。
4. **2025 年同类工作竞争加剧**：GenoRetriever 用可解释深度学习解码转录起始调控并识别 27 个核心启动子模体 [11]；DeepPlantCRE 用 Transformer-CNN 混合框架做跨物种表达预测与 CRE 提取 [12]；nemo 用分支 CNN + Shapley 归因捕捉启动子/终止子的位置特异效应 [13]。

2.2 2025 年同类工作与本课题对比

2.3 现有工作的不足与本课题切入点

3 研究目标与研究内容

3.1 总体目标

构建并评估一个**可解释、可迁移**的拟南芥”序列 → 表达”深度学习模型：在统一基准上系统对比 CNN 与 DNA 大模型；结合归因分析量化区域与模体贡献，解码顺式调控代码；并输出可验证的**调控变异效应预测**，形成纯干实验的应用闭环。

表 2 与本课题最相近的 2025 年同类工作对比

工作	架构	任务	可解释性	变异效应验证
GenoRetriever (2025)	可解释 DL	转录起始调控解码	模体发现（27 个核心启动子模体）+ 实验验证	无
DeepPlantCRE (预印本)	Transformer-CNN 混合	跨物种表达预测	CRE 提取	无
nemo (预印本)	分支 CNN	表达预测	Shapley 位置特异归因	无
Takou 2025	CNN	冷响应差异表达	模体分析	自然变异关联
本课题	CNN AgroNT 一对比	+ 双任务（分类/回归）	区域重要性 + 模体	1001 Genomes + eQTL 验证

表 3 现有工作不足与本课题对策

现有工作的不足	本课题对策
多数工作只用单一架构，缺乏统一基准下 CNN vs DNA 大模型的系统对比	在 PGB 标准基准 + 自建数据集上做双任务、多指标的严格对比，给出性能—成本权衡
可解释性多停留在模体发现，少有人量化”区域贡献”	DeepLIFT 归因聚合到区域级（启动子/UTR/终止子），量化各区域对表达的相对贡献
变异效应预测与自然变异验证（eQTL）结合少，缺乏纯干实验闭环	用 1001 Genomes + 公开 eQTL 数据验证模型 SNP 效应打分，替代湿实验

3.2 研究内容一：数据与基准构建

- **基因组/注释**: TAIR10 / Araport11 (Ensembl Plants 提取), 约 2.7 万个基因。
- **自建数据集**: 提取每个基因侧翼序列 (启动子 1kb + 5 UTR 0.5kb + 3 UTR 0.5kb + 终止子 1kb, 共约 3kb, 与 Peleke 口径一致); 表达量来自公开转录组 (叶片、根等多组织 RNA-seq, GEO/Expression Atlas), 构建高/低表达二分类标签 (中位数阈值) 与归一化表达量回归标签。
- **标准基准**: 接入 PGB 拟南芥基因表达任务 (6kb 序列, 训练 25,731 / 验证 3,401 / 测试 3,402) 作为独立测试床 [6]。
- **防泄漏**: 染色体级划分训练/验证/测试; 剔除同源基因簇, 避免序列同源导致的信息泄漏 (沿用 Peleke 方案) [2]。

3.3 研究内容二：统一基准模型对比

- **1D-CNN 基线**: 实现 DeepSEA 风格 (3 卷积块 + 池化 + 全连接) 与 Basenji 风格 (多卷积块 + 残差) 两种基线 [3, 4]。
- **DNA 大模型微调**: AgroNT-1B 在目标任务上做轻量微调 (LoRA 低秩适配, 冻结主干, 单卡可跑) [5]。
- **双任务评估**: 分类 (准确率/AUROC/AUPRC) + 回归 (R^2 /Pearson); 同时统计参数量、FLOPs、训练时间, 输出性能—成本权衡。
- **预期指标**: 参照 Peleke 水平设定——测试集分类准确率 $\geq 80\%$ 、AUROC ≥ 0.90 (预期标准, 以实际结果为准) [2]。

3.4 研究内容三：可解释性与调控代码解码

- **归因**: DeepLIFT/DeepSHAP 计算碱基级贡献得分 [8]。
- **区域重要性**: 将归因得分按启动子/5 UTR/3 UTR/终止子聚合, 量化各区域对表达的相对贡献 (延伸 Peleke 的 UTR 重要性发现) [2]。
- **模体发现与验证**: TF-MoDISco 聚类归因序列发现表达相关模体, 与 PlantCistrome DAP-seq peaks、JASPAR 植物模体比对 (STREME/TOMTOM), 确认生物真实性 [9]。

3.5 研究内容四：调控变异效应预测与自然变异验证 (差异化亮点)

- **in silico 变异打分**: 对基因侧翼区内 SNP/InDel 逐一替换参考序列, 计算模型预测差异 (Δ 表达概率/ Δ 表达量), 输出全基因组调控变异效应图谱。
- **自然变异验证**: 结合 1001 Genomes 拟南芥自然变异 (约千余生态型), 检验模型打分能否区分与 eQTL 关联的变异, 验证其调控效应预测能力。
- **跨物种泛化**: 将拟南芥训练模型迁移至水稻/玉米 (PGB 数据或侧翼序列), 分析调控代码的保守性与物种特异性。

4 技术路线

整体技术路线如图 1：数据自公开资源汇聚，经编码与防泄漏划分构建双轨数据集；模型层面并行开展 1D-CNN 基线与 AgroNT 微调，在统一基准上完成双任务评估；随后向可解释性分析、变异效应预测与跨物种迁移三个方向延伸，最终支撑论文撰写与投稿。

5 数据来源与方法详述

5.1 数据资源汇总

主要数据资源、获取方式与用途汇总于表 4，全部为公开资源，无需湿实验。

表 4 数据资源汇总

数据资源	内容	获取方式	用途
TAIR10 / Ara-port11	参考基因组、基因结构注释	Ensembl Plants / ara-bidopsis.org	侧翼序列提取
公开转录组	多组织表达量（叶片、根等）	GEO / Expression Atlas / AtGenExpress	表达标签
PGB (InstaDeepAI)	拟南芥基因表达任务 (6 kb, 约 2.5 万训练样本)	HuggingFace datasets	标准测试床
1001 Genomes	约千余生态型全基因组变异	1001genomes.org	变异效应验证
eQTL 数据	拟南芥公开 eQTL 结果	公开研究 (如 Kawakatsu 2016 等)	变异效应验证
PlantCistrome	DAP-seq 结合峰 (约千余 TF)	neomorph.salk.edu/PlantCistromeDB	模体验证
JASPAR 植物	已知 TF 结合模体	jaspar.genereg.net	模体验证

5.2 特征与标签

- 输入：One-hot 编码的基因侧翼序列。自建数据集为约 3kb（启动子 1kb + 5 UTR 0.5kb + 3 UTR 0.5kb + 终止子 1kb），PGB 任务为 6kb 基因窗口。
- 分类标签：以训练集全基因表达量中位数为阈值，划分高/低表达二分类标签 $y \in \{0, 1\}$ 。
- 回归标签：归一化（log 变换）的每基因平均表达量 $\tilde{y} \in \mathbb{R}$ 。
- 划分策略：按染色体整体划分训练/验证/测试集，并剔除同源基因簇，防止因序列同源导致的标签泄漏 [2]。

5.3 模型架构

(1) 1D-CNN 基线 参考 DeepSEA[3] 与 Basenji[4] 架构：




图 1 课题技术路线示意：双轨数据 → 双模型统一基准对比 → 可解释性 / 变异效应 / 跨物种三线分析 → 论文产出。

- DeepSEA 风格：3 个卷积块（1D 卷积 + BatchNorm + ReLU + 最大池化）→ 全局最大池化 → 两层全连接头；
- Basenji 风格：多卷积块 + 残差连接，捕获更长距离的调控上下文；
- 特点：参数少（百万级）、训练快、梯度流简单、便于 DeepLIFT 归因。
- **(2) DNA 大模型 AgroNT-1B** 加载 HuggingFace 预训练权重 [5]:
- 985M 参数 Transformer，40 层自注意力，6-mer token 词表，1024 token 上下文窗口；
- 采用 LoRA 低秩适配微调：冻结主干权重，仅训练注入到自注意力的 q/k/v/o 投影上的低秩矩阵（rank 16, $\alpha=32$ ）与轻量分类头，可训练参数占比约 1%-2%；
- 配合梯度检查点、混合精度（bf16）与梯度累积，单张 24 GB 显存 GPU 即可完成微调。

5.4 训练与优化

- 分类损失（交叉熵）：

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)] \quad (1)$$

- 回归损失（均方误差）：

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2 \quad (2)$$

- 优化器：AdamW（CNN 用 lr 10^{-3} 、weight decay 10^{-4} ；AgroNT 用 lr 2×10^{-4} 、weight decay 0.01），配合早停（监控验证集 AUROC）与学习率衰减。
- 算力：单张 RTX 4090/3090（24 GB）即可；CNN 分钟级训练，AgroNT LoRA 微调数小时级，必要时启用梯度累积与混合精度。

5.5 评估指标

- 准确率： $\text{Acc} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$ ；
- AUROC：以真正例率 TPR 对假正例率 FPR 的 ROC 曲线下面积，度量正负样本可分性；
- AUPRC：以精确率对召回率的 PR 曲线下面积，对类别不平衡更敏感；
- 回归指标： $R^2 = 1 - \frac{\sum_i (\hat{y}_i - y_i)^2}{\sum_i (y_i - \bar{y})^2}$ 与 Pearson 相关系数；
- 性能—成本：参数量、FLOPs、单 epoch 训练时间、峰值显存，四维对比 CNN 与 AgroNT。

5.6 可解释性方法

1. **DeepLIFT 归因**：通过激活差异的反向传播计算每个输入碱基对预测的贡献得分 [8]。以 One-hot 序列为输入，参考背景取平均碱基频率：

$$C_i = \text{DeepLIFT}_f(x)_i \approx \frac{\partial \hat{f}(x)}{\partial x_i} (x_i - \bar{x}_i) \quad (3)$$

2. **区域重要性**：将碱基级归因得分按启动子、5' UTR、3' UTR、终止子聚合（求和后按区域长度归一化），量化各区域对表达的相对贡献。

3. **模体发现与验证**: TF-MoDISco 对高贡献序列聚类, 发现表达相关模体; 用 TOMTOM 与 JASPAR 植物模体库、PlantCistrome DAP-seq 峰 (STREME 富集分析) 比对, 验证模体的生物真实性 [9]。

5.7 变异效应预测方法

1. **in silico 扰动打分**: 对基因侧翼区内每个 SNP/InDel, 将参考序列逐一替换为变异序列, 计算模型预测差异:

$$\Delta E(x, x^{\text{var}}) = f(x^{\text{var}}) - f(x) \quad (4)$$

输出全基因组”调控变异效应图谱” (效应方向、幅度与所在区域)。

2. **自然变异验证**: 以 1001 Genomes 常见变异与公开 eQTL 关联变异为功能变异集合, 检验模型打分能否显著区分功能变异与非功能变异 (Wilcoxon/Mann-Whitney 秩和检验、AUPRC 排序指标), 构成纯干实验证据链。
3. **跨物种泛化**: 将拟南芥训练模型零样本迁移至水稻/玉米 PGB 表达任务, 评估调控代码跨物种保守性。

6 预期成果与图件规划

6.1 预期成果

1. 可复现的拟南芥”序列 → 表达”数据构建与训练管线 (代码开源, 含数据集下载脚本);
2. 训练完成的 1D-CNN 与 AgroNT 微调模型 + 统一基准评估结果 (分类/回归双任务、性能—成本权衡);
3. 表达相关顺式模体清单、区域重要性分析与全基因组调控变异效应图谱;
4. 投稿中科院三区期刊的研究论文 1 篇 (4–5 幅主图 + 2–3 幅附图)。

6.2 图件规划 (4–5 主图 + 2–3 附图)

表 5 论文图件规划

图	内容	说明
图 1	研究概览与技术路线	概念图, 串联四大研究内容
图 2	数据集构建与基准	数据统计、防泄漏划分示意、任务设置
图 3	统一基准模型性能	分类/回归指标对比 + 性能—成本散点 (CNN vs AgroNT)
图 4	可解释性解码	归因示例、区域重要性条形图、TF-MoDISco 模体与 DAP-seq/JASPAR 比对
图 5	变异效应预测与验证	SNP 打分分布、eQTL/1001 Genomes 验证、跨物种泛化
附图	超参与消融 / 更多模体表 / 全基因组变异效应图	补充材料

7 工作量拆解与进度安排

对标 3 区论文，总计约 20 周（含投稿前准备），核心计算工作量约 6–8 周（GPU 运行），其余为数据、分析与撰写。

表 6 研究进度安排（20 周）

阶段	时间	主要工作	里程碑
文献与环境	第 1–2 周	精读核心文献；搭建 GPU 环境；下载数据资源	环境就绪
数据构建	第 3–5 周	侧翼序列提取、表达标签、PGB 接入、防泄漏划分	数据集完成
1D-CNN 基线	第 6–8 周	DeepSEA/Basenji 风格 CNN 实现、训练、调优	基线达预期指标
AgroNT 微调与对比	第 9–11 周	LoRA 微调、统一基准评估、性能—成本分析	图 3 完成
可解释性	第 12–13 周	DeepLIFT 归因、区域重要性、TF-MoDISco、DAP-seq/JASPAR 验证	图 4 完成
变异效应与应用	第 14–15 周	in silico 打分、1001 Genomes + eQTL 验证、跨物种迁移	图 5 完成
撰写与投稿	第 16–20 周	图件定稿、论文撰写、选刊与投稿	投稿完成

8 可行性分析

- 1. **数据可行**：全部为公开资源（TAIR10、PGB、1001 Genomes、PlantCistrome、eQTL），无需湿实验；2026-08-05 已实测 PGB（经 hf-mirror 镜像）、TAIR10、JASPAR 可直接下载，表达矩阵可从 PGB FASTA 头直接提取。
- 2. **方法可行**：DeepSEA/Basenji 风格 CNN 有成熟开源实现；AgroNT 提供公开预训练权重，LoRA 微调技术成熟 [5]；归因（DeepLIFT/captum）与模体发现（TF-MoDISco/TOMTOM）均有标准工具链。
- 3. **算力可行**：单物种约 2.7 万基因、序列 3–6 kb，CNN 单卡 GPU 分钟级训练；AgroNT LoRA 微调单卡（24 GB）可行，AutoDL 按小时计费可控。
- 4. **性能预期有据**：Peleke 已报道拟南芥分类准确率 >80%、AUROC 0.92–0.94[2]，本方案目标明确，AgroNT 在 PGB 上已有 SOTA 记录 [5]。
- 5. **纯干实验可信度**：以 PGB 独立基准 + 1001 Genomes 自然变异 + eQTL 三重计算验证补强证据链，符合无湿实验条件下审稿人对验证充分性的要求。

表 7 主要风险与对策

风险	概率	对策
回归任务性能不佳	中	主结果用高/低表达分类任务；回归作补充
AgroNT 微调算力/时间超支	低	LoRA 冻结主干 + 混合精度 + 梯度累积；必要时降输入长度
eQTL/自然变异验证不明显	中	备选验证：多生态型天然表达差异 / 跨物种迁移；三重验证取最优呈现
同类工作抢发(DeepPlantCRE 等)	中	突出” 统一基准 CNN vs 大模型 + 变异效应验证” 差异化；尽快产出核心图
纯干实验被审稿人质疑	中	用独立基准 + 自然变异 + eQTL 三重计算证据链；附图补充敏感性/消融

表 8 目标期刊定位

期刊	分区	说明
Genes (MDPI) (首选)	中科院 3 区 (生物学)	Takou 2025 同类型工作 (拟南芥 CNN 序列 → 表达 + 模体发现) 即发表于此 [7]，接受纯干实验 ML 论文，审稿较快，开放获取
Frontiers in Genetics	3 区	备选，接受组学与计算方法论文
BMC Genomics	大类 2 区/小类 3 区	备选，依当年分区
Planta / Scientific Reports	3 区	备选

9 风险与对策

10 三区期刊定位与选刊建议

注意事项：中科院分区每年更新，投稿前需以最新官方分区表为准；本方案工作量按 3 区标准设计，若分区变化或结果超出预期，可上探 2 区期刊（如 Plant Methods、BMC Plant Biology）。

11 前期基础与实现保障

本课题已具备以下前期基础，可显著降低实施风险：

1. **实现脚手架已就绪：**‘implementation/’ 目录提供一键可运行管线（数据下载 → 建集 → CNN 训练 → AgroNT LoRA 微调 → 统一评估 → 归因/模体 → 变异打分/eQTL 验证），对应论文图 2-5 的生成脚本均已预留。
2. **数据可用性已实测（2026-08-05）：**PGB 拟南芥表达任务（hf-mirror 国内镜像直下）、TAIR10 基因组与 GFF、JASPAR 植物模体库均验证可下载；表达矩阵可直接从 PGB FASTA 头提取，无需额外下载。
3. **算力方案已制定：**AutoDL RTX 4090/3090（24 GB）单卡实例选型、镜像、数据盘规划均已写明；当前已有数据下载实例与训练实例各一。
4. **参考文献已核验：**核心文献题录（DOI/PMID）已逐一核验，含 2025 年最新竞争工作（GenoRetriever、DeepPlantCRE、nemo、Takou 2025）。

12 总结

本方案以拟南芥为对象，构建“序列 → 表达”的可解释深度学习模型：以统一基准下 CNN 与 DNA 大模型的系统对比为方法贡献，以区域重要性量化和模体发现为可解释性贡献，以 1001 Genomes + eQTL 数据支撑的调控变异效应预测为差异化亮点，形成**纯干实验、单卡可行、工作量可控、验证充分**的三区期刊级研究方案。

参考文献

- [1] Marand A P, Eveland A L, Kaufmann K, Springer N M. cis-Regulatory elements in plant development, adaptation, and evolution[J]. *Annual Review of Plant Biology*, 2023, 74: 111–137.
- [2] Peleke F F, Zumkeller S M, Gültas M, Schmitt A, Szymański J. Deep learning the cis-regulatory code for gene expression in selected model plants[J]. *Nature Communications*, 2024, 15: 3488.
- [3] Zhou J, Troyanskaya O G. Predicting effects of noncoding variants with deep learning-based sequence model[J]. *Nature Methods*, 2015, 12(10): 931–934.
- [4] Avsec Ž, Agarwal V, Visentin D, Ledsam J R, Grabska-Barwińska A, et al. Effective gene expression prediction from sequence by integrating long-range interactions[J]. *Nature Methods*, 2021, 18(10): 1196–1203.
- [5] Mendoza-Revilla J, Trop E, Gonzalez L, Roller M, Dalla-Torre H, et al. A foundational large language model for edible plant genomes[J]. *Communications Biology*, 2024, 7: 835.

- [6] InstaDeepAI. Plants Genomic Benchmark (PGB): Arabidopsis gene expression prediction task[EB/OL]. HuggingFace: <https://huggingface.co/datasets/InstaDeepAI/plant-genomic-benchmark>.
- [7] Takou M, Bellis E S, Lasky J R. Predicting gene expression responses to cold in *Arabidopsis thaliana* using natural variation in DNA sequence[J]. *Genes*, 2025, 16(9): 1108.
- [8] Shrikumar A, Greenside P, Kundaje A. Learning important features through propagating activation differences[C]. *Proceedings of ICML*, 2017, 70: 3145–3153.
- [9] O’Malley R C, Huang S C, Song L, Lewsey M G, Bartlett A, Nery J R, et al. Cistrome and epicistrome features shape the regulatory DNA landscape[J]. *Cell*, 2016, 165(5): 1280–1292.
- [10] Hu X, Fernie A R, Yan J. Deep learning in regulatory genomics: from identification to design[J]. *Current Opinion in Biotechnology*, 2023, 79: 102887.
- [11] GenoRetriever authors. Deciphering the sequence basis and application of transcriptional initiation regulation in plant genomes through deep learning[J]. *Genome Biology*, 2025, 26: 293.
- [12] DeepPlantCRE authors. DeepPlantCRE: A Transformer-CNN hybrid framework for plant gene expression modeling and cross-species generalization[EB/OL]. arXiv preprint arXiv:2505.09883, 2025.
- [13] nemo authors. A deep learning model captures position-specific effects of plant regulatory sequences and suggests genes under complex regulation[EB/OL]. bioRxiv preprint 2025.08.30.673246, 2025.