

基于深度学习的拟南芥顺式调控代码解码 与基因表达预测——课题方案报告

姓名：_____ 学号：_____

专业：_____ 指导教师：_____

摘要

顺式调控元件（启动子、非翻译区、终止子等）是决定植物基因表达水平与组织特异性的关键序列要素，然而其“序列—调控”映射规律至今仍未完全解码。本课题以模式植物拟南芥（*Arabidopsis thaliana*）为研究对象，构建从基因侧翼序列到表达水平的端到端深度学习模型，系统解析决定基因表达高低的顺式调控代码。技术层面采用可解释的一维卷积神经网络（CNN），并结合 DeepLIFT 归因分析与 TF-MoDISco 模体发现揭示模型学到的序列特征；数据层面依托 TAIR10 基因组注释、公开转录组表达谱及 PlantCistrome DAP-seq 数据集。课题包含数据集构建、序列—表达预测建模、可解释性分析三项核心内容，并预留跨物种迁移与变异效应预测两项扩展。预期产出可复现的序列—表达预测管线与训练模型，为植物基因功能挖掘和分子设计育种提供计算工具。

关键词：拟南芥；深度学习；顺式调控元件；基因表达预测；可解释性

目录

1 选题背景与研究意义	3
1.1 研究背景	3
1.2 研究意义	3
2 国内外研究现状	3
2.1 深度学习在植物基因组学中的应用	3
2.2 从序列预测基因表达	3
2.3 转录因子结合位点与调控元件预测	4
2.4 现有方法的不足与本课题切入点	4
3 研究目标与研究内容	4
3.1 总体目标	4
3.2 研究内容一：序列—表达数据集的构建	4
3.3 研究内容二：序列—表达预测模型的构建与评估	4
3.4 研究内容三：模型可解释性分析	5
3.5 研究内容四：应用扩展	5

目录	2
4 技术路线	5
5 数据来源与研究方法	5
5.1 数据来源	5
5.2 特征与标签	5
5.3 模型架构	7
5.4 训练与评估	7
5.5 可解释性方法	7
6 预期成果与创新点	7
6.1 预期成果	7
6.2 创新点	7
7 研究计划与可行性分析	7
7.1 进度安排	7
7.2 可行性分析	8

1 选题背景与研究意义

1.1 研究背景

植物基因组中，编码区仅占很小一部分，而占据基因组主体的非编码区域承载着调控基因何时、何地、以何种水平表达的重要信息。这些功能由顺式调控元件（cis-regulatory element, CRE），如启动子（promoter）、5' 非翻译区（UTR）、3'UTR 与终止子（terminator）共同介导。解析 CRE 的序列编码规律，是理解基因表达调控、解释自然变异如何影响表型的关键前提，也是实现“从基因组到表型”预测的核心一环 [9]。

传统上，CRE 的功能注释依赖实验手段（如启动子截短报告系统、大规模平行报告基因分析），成本高、通量低，难以覆盖整个基因组。与此同时，以卷积神经网络（CNN）为代表的深度学习方法已在哺乳动物基因组上证明：仅从 DNA 序列即可高精度预测转录因子结合、染色质状态与基因表达 [4, 5]。将这一范式迁移到植物，有望以“序列即输入、功能即输出”的方式大规模注释植物基因组中的调控元件，并进一步指导育种中的靶向调控改造。

1.2 研究意义

- 科学意义：**以数据最全的模式植物拟南芥为对象，学习可解释的“序列—表达”映射模型，有助于揭示植物顺式调控代码的组成规律，回答“哪些序列特征、以何种组合方式决定表达水平”这一基础科学问题。
- 方法意义：**本课题将 CNN 与 DNA 大规模预训练模型（如 AgroNT[6]）进行系统对比，在统一的植物基准任务上考察预测性能与计算成本之间的权衡，为植物基因组深度学习建模提供方法参考。
- 应用价值：**训练得到的模型可直接用于（i）对基因组的全新基因进行表达水平预判；（ii）预测 SNP/插入缺失对表达的影响（即调控变异效应），为关联分析结果提供功能解释。

2 国内外研究现状

2.1 深度学习在植物基因组学中的应用

深度学习方法在植物基因组学中的应用近年快速增长，主要覆盖基因结构预测、转录因子结合位点预测、顺式调控元件识别、基因表达预测与基因组选择等任务。综述表明，该领域正从“预测”走向“解读与设计”：一方面模型输入从数百碱基扩展到数十万碱基（如 Enformer 风格的长序列建模），另一方面可解释性分析（归因、注意力、模体发现）逐渐成为标配 [3]。在植物中，1D-CNN 是当前最常用且效果稳定的架构，而以 AgroNT、DNABERT-2 为代表的 DNA 大模型为迁移学习提供了新的可能 [6]。

2.2 从序列预测基因表达

Peleke 等（2024）提出面向四种植物的可解释 CNN 模型，利用基因侧翼序列（启动子 1 kb、5'UTR 0.5 kb、3'UTR 0.5 kb、终止子 1 kb）预测基因表达高低，在拟南芥叶片与根中分别取得约 85%–87% 的分类准确率（AUROC 0.92–0.94），并通过 DeepLIFT 与 TF-MoDISco 识别出与已知转录因子结合位点一致的表达相关模体，同时展示了模型在跨物种与基因型间的迁移能

力 [1]。Takou 等 (2024) 进一步尝试仅从邻近序列预测胁迫下的差异表达基因，结果提示仅依赖近端序列预测环境响应性表达存在固有限制，需要整合染色质状态等额外信息 [7]。这些工作表明：基础表达水平的序列预测已相当可靠，而条件性/环境响应表达的预测仍具挑战，是本课题可以深入的空间。

2.3 转录因子结合位点与调控元件预测

O'Malley 等 (2016) 通过 DAP-seq 技术系统刻画了拟南芥 1800 余个转录因子的全基因组结合图谱，为序列建模提供了大规模标注数据 [2]。在此之上，DeepCistrome、deepTFBS、PTFSpot 等模型基于 PlantCistrome 数据实现了多标签的转录因子结合位点预测，并展现出跨物种迁移能力 [10]。该类任务与基因表达预测同属“序列—功能”映射，可为可解释性方法 (SHAP、DeepLIFT、模体发现) 的落地提供良好的测试床。

2.4 现有方法的不足与本课题切入点

综合现状，现有研究仍存在以下可改进之处：

1. 多数植物表达预测工作聚焦单一物种、单一架构，缺乏在统一基准上对 CNN 与 DNA 大模型的系统对比；
2. 可解释性分析多以模体发现为主，较少将预测模型与变异效应解释、跨物种泛化相结合，形成“序列—调控—表型”的完整链路；
3. 面向研一阶段的可复现、易上手的数据构建与训练管线仍显匮乏。

本课题以拟南芥为对象，在上述三点上设计研究内容，既保证可行性，又留有创新空间。

3 研究目标与研究内容

3.1 总体目标

构建并评估一个可解释的深度学习模型，实现从拟南芥基因侧翼序列到表达水平的端到端预测；结合归因分析挖掘决定表达高低的顺式序列特征，并验证模型在跨物种与变异效应预测上的泛化能力，形成一套可复现的植物“序列—表达”预测管线。

3.2 研究内容一：序列—表达数据集的构建

以 TAIR10 基因组与注释为参考，为拟南芥约 2.7 万个基因提取侧翼序列（启动子、5'UTR、3'UTR、终止子）；与公开转录组表达谱对齐，构建高/低表达二分类标签（以表达量中位数为阈值）或表达量回归标签；完成训练/验证/测试集划分，并按照染色体级别划分以避免序列同源导致的标签泄漏。同时引入 InstaDeepAI 植物基因组基准 (Plants Genomic Benchmark) 中的拟南芥基因表达任务作为标准测试床 [11]。

3.3 研究内容二：序列—表达预测模型的构建与评估

实现 Basenji/DeepSEA 风格的 1D-CNN 基线模型，以 One-hot 编码的侧翼序列为输入，输出表达分类（或回归）预测；在统一基准上评估准确率、AUROC、AUPRC 等指标；随后微调

AgroNT[6] 等 DNA 大模型，比较其与 CNN 在预测性能与计算成本上的权衡。

3.4 研究内容三：模型可解释性分析

采用 DeepLIFT 计算各序列碱基对预测的贡献得分，以 TF-MoDISco 聚类归因序列并发现表达相关模体，与 JASPAR/PlantCistrome 中已知转录因子结合位点比对，验证模型学到的序列特征是否具有生物学真实性。

3.5 研究内容四：应用扩展

(1) 跨物种迁移：考察在拟南芥上训练的模型向水稻、玉米基因组的迁移表现，分析序列特征的保守性；(2) 变异效应预测：利用训练好的模型对基因侧翼区内的 SNP/变异进行 in silico 扰动打分，评估其调控效应的预测能力。

4 技术路线

整体技术路线如图 1 所示，从数据准备出发，依次完成特征编码、数据集构建、模型设计、训练评估与可解释性分析，并延伸到跨物种迁移与变异效应预测。

5 数据来源与研究方法

5.1 数据来源

主要数据资源及其获取方式汇总于表 1。其中 TAIR10 提供基因组与注释，转录组表达谱提供基因表达标签，PlantCistrome 与 InstaDeepAI 基准分别服务于备选任务与标准评测。

表 1 主要数据资源汇总

数据资源	内容	获取方式
TAIR10 基因组与注释	拟南芥参考基因组、基因结构 (CDS/UTR/启动子/终止子) 注释	arabidopsis.org
转录组表达谱	拟南芥组织/条件表达量数据	GEO / eFP 数据库
PlantCistrome	DAP-seq 结合峰 (约 1000 个转录因子)	neomorph.salk.edu/ PlantCistromeDB
InstaDeepAI 植物基因组基准	拟南芥基因表达任务 (6kb 序列、约 2.5 万训练样本)	HuggingFace datasets

5.2 特征与标签

序列特征采用 One-hot 编码的基因侧翼区域 (默认长度约 3–6kb，覆盖启动子、5'UTR、3'UTR 与终止子)。标签方面，二分类任务以全基因组表达量中位数为阈值划分高/低表达；回归任务直接预测归一化表达量。划分数据时按染色体整体切分训练/验证/测试集，避免因序列同源或基因组邻近导致的信息泄漏。




图 1 课题技术路线示意：数据 → 特征编码 → 建模 → 评估 → 可解释性与应用扩展。

5.3 模型架构

1. **1D-CNN 基线**: 参考 Basenji/DeepSEA 架构, 由若干卷积层 + 池化 + 全连接头组成, 输入 One-hot 序列, 输出二分类或回归预测。该架构参数少、训练快、便于归因分析。
2. **DNA 大模型微调**: 对 AgroNT[6] 等预训练模型在目标数据集上进行轻量微调 (如 IA3/低秩适配), 作为与 CNN 对比的强基线。

5.4 训练与评估

分类任务使用交叉熵损失, 回归任务使用均方误差; 优化器采用 Adam (或 AdamW), 配合早停与学习率衰减。评估指标包括准确率 (accuracy)、AUROC 与 AUPRC。参照现有文献报道的拟南芥表达预测水平 (准确率约 85%、AUROC 0.92–0.94[1]), 本课题设定预期目标为: 测试集分类准确率不低于 80%, AUROC 不低于 0.90。该目标为预设的预期标准, 最终以真实实验结果为准。

5.5 可解释性方法

采用 DeepLIFT[8] 计算输入碱基对预测结果的贡献得分, 对贡献序列以 TF-MoDISco 进行聚类模体发现, 并将所得模体与 JASPAR、PlantCistrome 中的已知转录因子结合位点对比, 从序列层面验证模型学到的调控特征。

6 预期成果与创新点

6.1 预期成果

1. 一套可复现的拟南芥”序列—表达”数据构建与训练管线 (代码开源);
2. 训练完成的 1D-CNN 预测模型及其在统一基准上的评估结果;
3. 表达相关顺式模体清单与可解释性分析报告;
4. 研究报告一份 (并可整理为论文投稿)。

6.2 创新点

1. 在统一植物基准上系统对比 1D-CNN 与 DNA 大模型在基因表达预测任务上的性能—成本权衡;
2. 将”预测 + 归因 + 模体发现”与”跨物种迁移 + 变异效应预测”串成完整链路, 形成从序列到调控功能的应用闭环;
3. 面向研一阶段设计轻量、可复现、易上手的实现方案。

7 研究计划与可行性分析

7.1 进度安排

按 16 周安排, 见表 2。

表 2 研究进度安排

阶段	时间	主要工作
文献调研	第 1–2 周	精读核心文献，确定数据源与基线方案
数据构建	第 3–5 周	侧翼序列提取、表达量处理、数据集划分与防泄漏校验
模型实现	第 6–8 周	1D-CNN 基线实现、训练与超参调优
评估与对比	第 9–10 周	统一基准评估，与 DNA 大模型微调结果对比
可解释性	第 11–12 周	DeepLIFT 归因、TF-MoDISco 模体发现与对比
扩展与撰写	第 13–16 周	跨物种/变异效应扩展，报告与论文撰写

7.2 可行性分析

1. **数据可行**：TAIR10、PlantCistrome、InstaDeepAI 基准均为公开资源，无需湿实验即可获得；
2. **方法可行**：Basenji/DeepSEA 风格 CNN 有成熟开源实现，AgroNT 提供公开预训练权重，技术路线有清晰参照；
3. **算力可行**：单物种约 2.7 万个基因，序列长度 3–6 kb，CNN 训练在单张消费级 GPU（或 Google Colab 的 T4/A100）上即可完成；大模型微调按需使用云端算力；
4. **规模可控**：课题范围聚焦拟南芥单物种，复杂度适合研一阶段独立完成，并可按进展扩展。

参考文献

[1] Peleke F F, Zumkeller S M, Gültas M, Schmitt A, Szymański J. Deep learning the cis-regulatory code for gene expression in selected model plants[J]. *Nature Communications*, 2024, 15: 3488.

[2] O’Malley R C, Huang S C, Song L, Lewsey M G, Bartlett A, Nery J R, Galli M, Gallavotti A, Ecker J R. Cistrome and epicistrome features shape the regulatory DNA landscape[J]. *Cell*, 2016, 165(5): 1280–1292.

[3] Hu X, Fernie A R, Yan J. Deep learning in regulatory genomics: from identification to design[J]. *Current Opinion in Biotechnology*, 2023, 79: 102887.

[4] Zhou J, Troyanskaya O G. Predicting effects of noncoding variants with deep learning-based sequence model[J]. *Nature Methods*, 2015, 12(10): 931–934.

[5] Avsec Ž, Agarwal V, Visentin D, Latham J R, Djebali S, et al. Effective gene expression prediction from sequence by integrating long-range interactions[J]. *Nature Genetics*, 2021, 53(7): 1116–1122.

[6] Mendoza-Revilla J, Trop E, Gonzalez L, Roller M, Dalla-Torre H, et al. A foundational large language model for edible plant genomes[J]. *Communications Biology*, 2024, 7: 835.

[7] Takou M, et al. Predicting gene expression responses to environment in *Arabidopsis thaliana* using natural variation in DNA sequence[J/OL]. bioRxiv, 2024. DOI: 10.1101/2024.04.25.591174.

[8] Shrikumar A, Greenside P, Kundaje A. Learning important features through propagating activation differences[C]. *Proceedings of ICML*, 2017, 70: 3145–3153.

[9] Marand A P, Eveland A L, Kaufmann K, Springer N M. cis-Regulatory elements in plant development, adaptation, and evolution[J]. *Annual Review of Plant Biology*, 2023, 74: 111–137.

- [10] NAMlab. DeepCistrome: multi-label deep learning classifiers for DNA–TF binding (PlantCistrome-based)[EB/OL]. GitHub: <https://github.com/NAMlab/DeepCistrome>.
- [11] InstaDeepAI. Plants Genomic Benchmark (PGB): 拟南芥基因表达预测任务数据集 [EB/OL]. HuggingFace: <https://huggingface.co/datasets/InstaDeepAI/plant-genomic-benchmark>.